



Departamento de
Ingeniería Industrial
Universidad de Concepción

Homework Assignment No. 3

Preferencias de sushi en Japón: un análisis de elección discreta de la heterogeneidad del consumidor

Understanding Consumer Behavior through Discrete Choice Models
2026–1

Realizado por:

Matías Arriagada R. 2022445068 matiaarriagada2022@udec.cl

Profesor:

Ph. D. Sebastián Astroza Tagle

4 de julio de 2026, Concepción, Chile

Índice

1. Introducción	2
2. Model Specification and Estimation (Sección A)	2
2.1. Datos	2
2.2. Estrategia de identificación	3
2.3. M1 — MNL solo con atributos (Set A)	4
2.4. M2 — MNL solo con ASCs (benchmark)	5
2.5. M3 — MNL con ASCs + interacciones demográficas (modelo preferido)	5
2.6. M4 — Nested Logit sobre ranking explotado	6
2.7. M5-LC — Modelo de clases latentes	8
2.8. M6 — MNL de atributos sobre el Set B (validación externa)	9
2.9. Comparación de modelos	10
2.10. Validación cruzada Python–Apollo y robustez	10
3. Parameter Interpretation and Behavioral Insights (Sección B)	11
3.1. El precio como señal de calidad	11
3.2. Edad y preferencia por la grasa	11
3.3. Heterogeneidad regional Este–Oeste	12
3.4. Patrones de sustitución: IIA rechazado	12
3.5. Segmentos latentes de consumidores	13
3.6. Calidad no observada de los ítems	13
3.7. Limitaciones	13
4. Scenario Analysis and Prediction (Sección C)	14
4.1. Escenario A — Shock de oferta del toro (+40 % precio)	14
4.2. Escenario B — Promoción saludable (kappa-maki)	15
4.3. Escenario C — Entrada del California roll	16
4.4. Escenario D — Campaña regional Kinki	17
5. Strategic and Public Policy Recommendations (Sección D)	17
5.1. Para cadenas de restaurantes y retail de sushi	17
5.2. Para la política de salud pública	18
5.3. Para la preservación cultural regional	18
5.4. Recomendaciones metodológicas para trabajo futuro	18
Bibliografía	19
Linkografía	19
A. Apéndice: trade-offs relativos entre atributos	20
B. Apéndice: estructura del repositorio de código	20

1. Introducción

¿Qué determina las preferencias de los consumidores japoneses por el sushi? ¿Cómo moderan la edad, el género y el origen regional el gusto por la grasa y la sensibilidad al precio? Este informe utiliza el *SUSHI Preference Dataset* (Kamishima, 2003) —una encuesta de preferencias declaradas en que 5.000 consumidores japoneses ordenaron tipos de sushi de mayor a menor preferencia— para estimar una cadena de modelos de elección discreta y simular escenarios contrafactuales de política y mercado.

El dataset ofrece una ventana única a una decisión de consumo culturalmente arraigada. A diferencia de los datos de elección estándar, donde los atributos varían dentro de cada choice set, los ítems de sushi tienen atributos (precio, nivel de grasa, frecuencia de venta) que son *constantes entre encuestados*. Esta propiedad de diseño condiciona toda la estrategia de identificación (Sección 2.2) y distingue este análisis de las aplicaciones de libro de texto.

El informe se organiza en torno a las cuatro secciones exigidas por la pauta:

- **Sección A:** especificación y estimación de modelos (M1–M6, incluyendo un modelo de clases latentes).
- **Sección B:** interpretación de parámetros e insights de comportamiento.
- **Sección C:** análisis de escenarios contrafactuales (4 escenarios).
- **Sección D:** recomendaciones estratégicas y de política pública.

Todo el código (Python + R/Apollo) se entrega como pipeline reproducible en una carpeta compartida (ver Linkografía).

2. Model Specification and Estimation (Sección A)

2.1. Datos

El *SUSHI Preference Dataset* (Kamishima, 2003) contiene:

- **Set A:** 10 tipos de sushi ordenados por los 5.000 usuarios de más a menos preferido. Los ítems son **ebi** (camarón), **anago** (anguila de mar), **maguro** (atún), **ika** (calamar), **uni** (erizo), **ikura** (huevas de salmón), **tamago** (huevo), **toro** (atún graso), **tekka_maki** (rollo de atún) y **kappa_maki** (rollo de pepino). Los shares de primera preferencia observados se muestran en la Figura 1.
- **Set B:** 100 tipos de sushi; cada usuario rankea 10 de ellos. Para estimación se usa el ítem elegido más 9 alternativas muestreadas uniformemente (McFadden, 1978).
- **Demografía:** género, grupo etario (6 tramos, 15–19 a 60+), región de residencia (12 regiones, colapsadas a Japón Oriental/Occidental) e indicador de migración.

Cada ítem del Set A tiene tres atributos continuos: **price_norm** [1,02–4,49], **oiliness** [0,27–3,45; recodificada para que mayor = más grasoso] y **freq_sold** [0,40–0,92]. Adicionalmente, los atributos categóricos (**style**: maki/otro; **major_group**: pescado-marisco/otro) se usan para definir nidos y como regresores en el Set B.




Figura 1: Shares de primera preferencia observados, Set A ($N = 5,000$). Toro domina con 34,3 %, seguido de uni (14,9 %) y anago (11,0 %).




Figura 2: Espacio de atributos del Set A: precio vs. oiliness, con tamaño de burbuja proporcional al share. Nótese la fuerte asociación entre grasa y popularidad: toro, uni y anago forman el cluster superior derecho.

2.2. Estrategia de identificación

Una propiedad crítica del diseño del Set A es que los tres atributos continuos (`price_norm`, `oiliness`, `freq_sold`) son *constantes por ítem*: los 5.000 usuarios ven vectores de atributos idénticos. Con 10 alternativas existen a lo más 9 parámetros independientes de variación “entre alternativas”, y una especificación que contenga simultáneamente el set

completo de constantes específicas (ASCs, 9 parámetros) y betas genéricos de atributos sería **perfectamente colineal e inestimable**.

Esto no es un error de datos sino una propiedad del diseño. Se maneja anidando modelos y sin combinar nunca ASCs completos con betas de atributos en la misma especificación:

$$M1 \text{ (3 betas)} \subset M2 \text{ (9 ASCs)} \subset M3 \text{ (9 ASCs + interacciones)}$$

Las interacciones demográficas (p.ej. $\text{oiliness}_j \times \text{edad}_n$) sí son identificables junto a ASCs completos porque varían entre individuos. Esta cadena anidada permite tests de razón de verosimilitud (LR) limpios en cada eslabón.

Adicionalmente, $\text{corr}(\text{precio}, \text{oiliness}) = 0,82$ dentro del Set A (Figura 3): multicolinealidad severa con solo 10 ítems. Los errores estándar de M1 estarán inflados; se valida externamente con M6 sobre el Set B de 100 ítems, donde la correlación es menor.

Para los escenarios que requieren simultáneamente ASCs y un coeficiente de precio (p.ej. el shock de precio del toro) se usa el enfoque estándar de *constantes calibradas* (Train, 2009): las constantes C_j se eligen de modo que la predicción base reproduzca exactamente los shares observados, mientras el coeficiente β_{precio} proviene de M1 o M6.




Figura 3: Matriz de correlación de los tres atributos continuos en el Set A ($n = 10$ ítems). $\rho(\text{precio}, \text{oiliness}) = 0,82$: toro es a la vez el ítem más grasoso y el más caro.

2.3. M1 — MNL solo con atributos (Set A)

El modelo más simple explica la preferencia usando únicamente los tres atributos continuos:

$$U_{nj} = \beta_{\text{precio}} \cdot \text{price}_j + \beta_{\text{oil}} \cdot \text{oiliness}_j + \beta_{\text{freq}} \cdot \text{freq_sold}_j + \varepsilon_{nj} \quad (1)$$

donde $\varepsilon_{nj} \sim \text{i.i.d. Valor Extremo Tipo I}$. Estimación: máxima verosimilitud vía BFGS con gradiente analítico (Python, scipy). Errores estándar desde la matriz de información observada.

Tabla 1: M1 — MNL solo atributos, Set A ($N = 5,000$, $K = 3$)

Parámetro	Coeficiente	EE	z	p	IC 95 %
β_{precio}	0,581	0,024	24,12	$< 10^{-3}$	[0,534; 0,629]
β_{oiliness}	0,085	0,036	2,38	0,017	[0,015; 0,156]
$\beta_{\text{freq_sold}}$	2,173	0,172	12,64	$< 10^{-3}$	[1,837; 2,510]

$$\text{LL} = -9.850,73 \quad \rho^2 = 0,144 \quad \text{AIC} = 19.707,5$$

Hallazgo: $\beta_{\text{precio}} > 0$, estadísticamente significativo ($z = 24,1$). En una encuesta de preferencias declaradas donde los encuestados no pagan, el precio actúa como *señal de calidad*: el sushi caro (toro, uni) se percibe como de mayor calidad, no como un costo a minimizar. Este confounding entre precio y calidad no observada se discute en la Sección 3.1. La consecuencia es que los ratios de disposición a pagar (WTP) no son interpretables monetariamente; se reportan solo como trade-offs relativos entre atributos (Apéndice A).

2.4. M2 — MNL solo con ASCs (benchmark)

El modelo saturado con constantes específicas por alternativa reproduce exactamente los shares observados (por construcción):

$$U_{nj} = \text{ASC}_j + \varepsilon_{nj}, \quad \text{ASC}_{\text{ebi}} = 0 \text{ (referencia)} \quad (2)$$

Tabla 2: M2 — MNL con ASCs, Set A ($K = 9$)

Parámetro	Coef.	EE	z	p	IC 95 %
$\text{ASC}_{\text{anago}}$	0,183	0,063	2,89	0,004	[0,059; 0,307]
$\text{ASC}_{\text{maguro}}$	-0,125	0,068	-1,84	0,066	[-0,259; 0,008]
ASC_{ika}	-0,698	0,081	-8,61	$< 10^{-3}$	[-0,856; -0,539]
ASC_{uni}	0,489	0,059	8,24	$< 10^{-3}$	[0,373; 0,606]
$\text{ASC}_{\text{ikura}}$	0,174	0,063	2,74	0,006	[0,050; 0,298]
$\text{ASC}_{\text{tamago}}$	-0,799	0,084	-9,52	$< 10^{-3}$	[-0,963; -0,635]
ASC_{toro}	1,319	0,053	25,08	$< 10^{-3}$	[1,216; 1,422]
$\text{ASC}_{\text{tekka_maki}}$	-1,399	0,105	-13,32	$< 10^{-3}$	[-1,605; -1,194]
$\text{ASC}_{\text{kappa_maki}}$	-2,543	0,173	-14,69	$< 10^{-3}$	[-2,883; -2,204]

$$\text{LL} = -9.755,07 \quad \rho^2 = 0,153 \quad \text{AIC} = 19.528,1$$

Test LR M1 vs. M2: LR = 191,3, gl = 6, $p < 10^{-3}$. Los tres atributos observables *no* capturan completamente las preferencias por ítem: existe calidad no observada sustancial (prestigio, complejidad de sabor, asociaciones culturales). Una regresión OLS descriptiva de los 9 ASCs sobre los 3 atributos entrega $R^2 = 0,95$: el 95 % de la variación entre ítems se explica por precio, grasa y disponibilidad, pero el 5 % restante es estadística y conductualmente significativo.

2.5. M3 — MNL con ASCs + interacciones demográficas (modelo preferido)

M3 extiende M2 con tres interacciones demográficas, que varían entre individuos y por tanto son identificables junto a los ASCs completos:

$$U_{nj} = \text{ASC}_j + \beta_{\text{precio} \times \text{oeste}} \cdot \text{price}_j \cdot \text{oeste}_n + \beta_{\text{oil} \times \text{edad}} \cdot \text{oiliness}_j \cdot \text{edad}_n + \beta_{\text{oil} \times \text{oeste}} \cdot \text{oiliness}_j \cdot \text{oeste}_n + \varepsilon_{nj} \quad (3)$$

donde $\text{oeste}_n = 1$ si la región actual del encuestado está en Japón Occidental y edad_n es el grupo etario (0–5, tratado como lineal).

Tabla 3: M3 — MNL con ASCs e interacciones demográficas ($K = 12$)

Parámetro	Coef.	EE	z	p	IC 95 %
<i>Constantes específicas (ref.: ebi)</i>					
ASC _{anago}	−0,084	0,094	−0,90	0,369	[−0,267; 0,099]
ASC _{maguro}	−0,265	0,077	−3,42	0,001	[−0,416; −0,113]
ASC _{ika}	−0,711	0,081	−8,75	$< 10^{-3}$	[−0,870; −0,551]
ASC _{uni}	0,231	0,090	2,57	0,010	[0,055; 0,406]
ASC _{ikura}	−0,025	0,082	−0,31	0,758	[−0,185; 0,135]
ASC _{tamago}	−0,869	0,087	−10,00	$< 10^{-3}$	[−1,040; −0,699]
ASC _{toro}	1,041	0,092	11,32	$< 10^{-3}$	[0,861; 1,221]
ASC _{tekka_maki}	−1,475	0,107	−13,78	$< 10^{-3}$	[−1,684; −1,265]
ASC _{kappa_maki}	−2,426	0,176	−13,78	$< 10^{-3}$	[−2,771; −2,081]
<i>Interacciones demográficas</i>					
$\beta_{\text{precio} \times \text{oeste}}$	−0,066	0,045	−1,46	0,143	[−0,155; 0,022]
$\beta_{\text{oil} \times \text{edad}}$	0,089	0,017	5,20	$< 10^{-3}$	[0,055; 0,123]
$\beta_{\text{oil} \times \text{oeste}}$	−0,058	0,067	−0,86	0,389	[−0,189; 0,074]

LL = −9.733,21 $\rho^2 = 0,155$ AIC = 19.490,4 $N = 5,000$

Test LR M2 vs. M3: LR = 43,7, gl = 3, $p = 1,7 \times 10^{-9}$. M3 se prefiere sobre M2: la heterogeneidad demográfica es real y significativa.

Test LR M3r vs. M3 (eliminando las dos interacciones con Oeste, de $|z| < 1,96$): LR = 15,6, gl = 2, $p = 4,1 \times 10^{-4}$. Las interacciones asociadas al Oeste, aunque individualmente no significativas, son *conjuntamente* significativas; se retiene la especificación completa M3.

2.6. M4 — Nested Logit sobre ranking explotado

Para relajar el supuesto IIA e investigar patrones de sustitución, se estima un Nested Logit sobre el *ranking explotado* (ranks 1–3 por usuario). Cada usuario genera tres pseudo-elecciones con choice sets decrecientes (10, 9 y 8 alternativas), aportando 15.000 pseudo-observaciones que contienen la información de sustitución observada (Beggs, Cardell y Hausman, 1981).




Figura 4: Clustering jerárquico de ítems según correlación de ranks entre usuarios. El nido **akami** (maguro, toro, tekka_maki) emerge empíricamente, validando la estructura de nidos usada en M4.

Se definen tres nidos por ingrediente principal (Figura 4):

1. **akami**: maguro, toro, tekka_maki (atún en tres formatos)
2. **seafood_other**: ebi, anago, ika, uni, ikura
3. **non_seafood**: tamago, kappa_maki (huevo y vegetal)

Los parámetros log-sum $\lambda_m \in (0, 1]$ miden la correlación intra-nido: $\lambda_m = 1$ implica MNL dentro del nido; $\lambda_m \rightarrow 0$ implica sustitutos perfectos.

Tabla 4: M4 — Nested Logit, ranking explotado ranks 1–3 ($N_{\text{pseudo}} = 15,000$)

Parámetro	Estimación	EE	t (vs. $\lambda = 1$)	p
λ_{akami}	0,325	0,026	−26,08	$< 10^{-3}$
$\lambda_{\text{seafood_other}}$	0,336	0,053	−12,55	$< 10^{-3}$
$\lambda_{\text{non_seafood}}$	0,002	0,009	−115,65	$< 10^{-3}$

LL(M4) = −29.112,13 LL(M2_{exp}) = −29.446,46 LR = 668,7, gl = 3, $p \approx 0$

Los tres $\lambda_m < 1$: IIA se rechaza en todos los nidos.

Hallazgo: IIA se rechaza contundentemente (LR = 668,7, $p \approx 0$). El parámetro $\lambda_{\text{akami}} = 0,33$ implica que maguro, toro y tekka_maki son sustitutos mucho más cercanos de lo que el MNL predice: cuando el atún favorito no está disponible, el consumidor migra desproporcionadamente hacia otro ítem del mismo nido. El $\lambda_{\text{non_seafood}} \rightarrow 0$ indica que tamago y kappa_maki son sustitutos casi perfectos —típicamente el “plan B” de quien evita pescado.

Variante M4b (nido degenerado). El $\lambda_{\text{non_seafood}} = 0,002$ está en la frontera del espacio paramétrico: es un artefacto de nido degenerado (2 ítems con shares 4,1 % y 0,7 %) y no un parámetro de sustitución creíble para predicción. Se estima por robustez la variante M4b con $\lambda_{\text{non_seafood}} = 1$ fijo: LL(M4b) = −29,159,70. En ajuste muestral BIC prefiere M4 (58.339,7 vs. 58.425,2), pero **para las simulaciones contrafactuales de la Sección C se usa M4b**: un λ en la frontera haría que tamago y kappa_maki se comporten como un solo ítem al filo de la navaja, contaminando las predicciones. Ambas variantes se reportan.

2.7. M5-LC — Modelo de clases latentes

Como especificación avanzada con variables latentes, se estima un *Latent Class MNL* en Apollo (R) sobre el mismo panel explotado de M4 (3 pseudo-elecciones por usuario; la agrupación panel es la que identifica las clases: los 3 ranks de una persona deben provenir de la misma clase). Cada clase s tiene su propio set completo de ASCs ($\text{ebi} = 0$ como referencia dentro de cada clase) y la probabilidad de pertenencia sigue un logit sobre demografía observada:

$$\pi_{ns} = \frac{\exp(\delta_s + \gamma_{\text{edad},s} \text{edad}_n + \gamma_{\text{oeste},s} \text{oeste}_n + \gamma_{\text{mujer},s} \text{mujer}_n + \gamma_{\text{mig},s} \text{mig}_n)}{\sum_{s'} \exp(\cdot)} \quad (4)$$

Dentro de cada clase las utilidades son ASCs puros: por la restricción de identificación de la Sección 2.2, betas de atributos específicos por clase serían colineales con los ASCs de la clase. La heterogeneidad se lee en *cómo difieren los ASCs entre clases*.

Se estiman especificaciones con $S = 2$ y $S = 3$ clases; la selección usa BIC contra el benchmark de una clase ($M2_{\text{exp}}$):

Tabla 5: M5-LC — selección del número de clases ($N_{\text{pseudo}} = 15,000$)

Modelo	K	LL	BIC
$M2_{\text{exp}} (S = 1)$	9	-29.446,5	58.979,5
$LC2 (S = 2)$	23	-28.943,0	58.107,2
$LC3 (S = 3)$	37	-28.513,7	57.383,3

LR $LC3$ vs. $S = 1$: 1,865,4, $gl = 28$, $p \approx 0$. BIC selecciona **3 clases**.

Tabla 6: M5-LC3 — ASCs por clase (ref.: ebi = 0) y modelo de membresía

Parámetro	Clase a “gourmet premium”	Clase b “gusto ligero”	Clase c “fanático del atún”
<i>ASCs por clase (t-ratios entre 3,0 y 21,2 salvo indicación)</i>			
ASC _{anago}	0,346	−0,380	0,302
ASC _{maguro}	−0,554	−0,576	1,464
ASC _{ika}	−0,847	−0,493	−0,494
ASC _{uni}	1,850	−2,187	−0,081 [†]
ASC _{ikura}	0,917	−0,737	0,294
ASC _{tamago}	−2,176	−0,660	−1,219
ASC _{toro}	1,408	−0,600	2,838
ASC _{tekka_maki}	−2,083	−1,132	0,150 [†]
ASC _{kappa_maki}	−3,366	−1,730	−2,842
<i>Membresía (logit multinomial; ref.: clase c)</i>			
δ (constante)	−0,630 (t −3,9)	−0,348 (t −2,0)	—
γ _{edad}	0,176 (t 3,8)	−0,117 (t −2,3)	—
γ _{oeste}	0,128 (t 1,2)	0,356 (t 3,3)	—
γ _{mujer}	0,384 (t 3,9)	0,811 (t 7,9)	—
γ _{migró}	0,037 (t 0,4)	−0,273 (t −2,6)	—
<i>Perfil posterior de las clases</i>			
Share de clase	33,7 %	31,3 %	34,9 %
Grupo etario promedio	2,13 (el mayor)	1,76 (el más joven)	1,97
% Japón Occidental	30,2 %	35,7 %	27,7 %
% mujeres	51,1 %	64,3 %	43,4 %

[†] no significativo al 5 %. Fuente: `latent_class_results.csv`, `latent_class_profiles.csv`.

La interpretación conductual de las tres clases se desarrolla en la Sección 3.5.

2.8. M6 — MNL de atributos sobre el Set B (validación externa)

La misma especificación de atributos (Ec. 1) se estima sobre el Set B (universo de 100 ítems, choice sets muestreados), extendida con dos dummies de tipo: `maki` (rollo maki) y `non_seafood` (no pescado/marisco). El Set B ofrece mucha más variación de atributos entre sus 100 ítems, y el muestreo uniforme satisface la *uniform conditioning property* de McFadden (1978): el MNL es consistente sin corrección.

 Tabla 7: M6 — MNL de atributos, Set B ($N = 5,000$, $K = 5$)

Parámetro	Coef.	EE	z	p	IC 95 %
β_{precio}	0,251	0,023	10,97	$< 10^{-3}$	[0,206; 0,295]
β_{oiliness}	0,416	0,024	17,22	$< 10^{-3}$	[0,368; 0,463]
$\beta_{\text{freq_sold}}$	4,303	0,070	61,22	$< 10^{-3}$	[4,165; 4,440]
β_{maki}	0,586	0,081	7,19	$< 10^{-3}$	[0,426; 0,745]
$\beta_{\text{non-seafood}}$	−0,375	0,075	−4,99	$< 10^{-3}$	[−0,523; −0,228]

LL = −7.230,97 $\rho^2 = 0,372$ AIC = 14.471,9

Validación externa: M6 confirma el mismo patrón de signos que M1: $\beta_{\text{precio}} > 0$, $\beta_{\text{oiliness}} > 0$, $\beta_{\text{freq_sold}} > 0$. La dummy maki es positiva (+0,586) y la de no-pescado negativa (−0,375), consistente con el patrón observado en los shares del Set A. Los betas de M6 alimentan los escenarios C y D del Set B.

2.9. Comparación de modelos

Tabla 8: Comparación de modelos de la cadena de estimación

Modelo	N	K	LL	ρ^2	AIC	BIC
M1 (atributos)	5.000	3	−9.850,7	0,144	19.707,5	19.727,0
M2 (ASCs)	5.000	9	−9.755,1	0,153	19.528,1	19.586,8
M3 (interacciones)	5.000	12	−9.733,2	0,155	19.490,4	19.568,6
M3r (restringido)	5.000	10	−9.741,0	0,154	19.502,0	19.567,2
M2 _{exp} (MNL explotado)	15.000	9	−29.446,5	—	58.910,9	58.979,5
M4 (NL explotado)	15.000	12	−29.112,1	—	58.248,3	58.339,7
M4b (NL, $\lambda_{ns} = 1$)	15.000	11	−29.159,7	—	58.341,4	58.425,2
LC2 ($S = 2$, explotado)	15.000	23	−28.943,0	—	57.932,0	58.107,2
LC3 ($S = 3$, explotado)	15.000	37	−28.513,7	—	57.101,5	57.383,3
M6 (Set B)	5.000	5	−7.231,0	0,372	14.471,9	14.504,5

LL₀ (shares iguales) = −11.512,93 en Set A y Set B.

Los modelos sobre datos explotados ($N_{\text{pseudo}} = 15,000$) no son comparables en LL con M1–M3.

M3 es el modelo preferido para interpretación conductual; M4/M4b aportan la sustitución.

2.10. Validación cruzada Python–Apollo y robustez

1. **Validación cruzada con Apollo (R).** Todos los modelos principales se re-estimaron en Apollo 0.3.7 como motor de máxima verosimilitud independiente de la implementación propia en Python/scipy. Las log-verosimilitudes coinciden: M1 (−9.850,731 vs. −9.850,73; $\Delta = 0,001$), M2 ($\Delta = 0,001$), M3 ($\Delta = 0,004$), M2_{exp} ($\Delta = 0,00$) y M4b ($\Delta = 0,01$); los coeficientes coinciden a 4 decimales (p.ej. β_{precio} de M1: 0,581333 en Apollo vs. 0,58133 en Python). El M4 sin restricciones no es estimable en Apollo: su optimizador BGW produce NaN cuando $\lambda_{\text{non_seafood}}$ se aproxima a la frontera $\lambda \rightarrow 0$ (la implementación Python usa reparametrización exponencial y *logsumexp* para manejarla); esta es precisamente la razón por la que M4b es la variante usada para predicción. El modelo de clases latentes (M5-LC), estimado directamente en Apollo, se verificó reconstruyendo su verosimilitud de forma manual e independiente en 04_lc_postprocess.R: la LL reconstruida coincide con la de Apollo al centésimo (−28.513,74 en ambos casos).
2. **Exclusión de los autores del dataset:** los usuarios 323, 617, 1431 y 4667 son los autores del paper (Kamishima, 2003). Re-estimar M3 sin ellos cambia los coeficientes en a lo más $|\Delta\beta| = 0,003$: despreciable.
3. **Estabilidad de ranks:** los ASCs estimados solo con la primera elección vs. con ranks 1–3 explotados difieren hasta en 6 errores estándar para maguro y tekka_maki (que funcionan como “segunda opción” sistemática) y para uni (que polariza: se ama

o se odia). Esta deriva es una limitación declarada de la explosión de rankings (Sección 3.7) y, a la vez, evidencia directa de heterogeneidad de gustos —la motivación del modelo de clases latentes (Sección 2.7).

3. Parameter Interpretation and Behavioral Insights (Sección B)

3.1. El precio como señal de calidad

Tanto M1 ($\beta_{\text{precio}} = +0,581$, $z = 24,1$) como M6 ($\beta_{\text{precio}} = +0,251$, $z = 11,0$) entregan un coeficiente de precio positivo y altamente significativo. En un contexto de elección convencional donde el consumidor paga, β_{precio} sería negativo (mayor precio $\rightarrow$ menor utilidad). Aquí el signo opuesto surge porque se trata de una **encuesta de ranking de preferencias sin restricción presupuestaria**: el consumidor expresa *preferencia*, no *compra*. Los ítems más caros (toro en 4,49; uni en 3,29) son también los más preferidos: el precio opera como **señal de calidad** y no como costo.

Esto no es una falla del modelo sino un hallazgo conductual válido para este dataset. Las consecuencias son:

- Los ratios WTP calculados por método delta **no son interpretables como disposición a pagar monetaria**. Se reportan solo como trade-offs relativos (Apéndice A).
- Los escenarios contrafactuales de precio deben interpretarse con cautela: en este modelo un *aumento* de precio eleva la utilidad (señala mayor calidad), lo contrario de la intuición económica estándar.

3.2. Edad y preferencia por la grasa

La interacción $\beta_{\text{oil} \times \text{edad}} = +0,089$ es el hallazgo conductual más fuerte de M3 ($z = 5,2$, $p < 10^{-6}$). Los consumidores japoneses de mayor edad derivan sistemáticamente más utilidad del sushi grasoso, incluso después de controlar por la preferencia promedio de cada ítem (capturada en los ASCs).




Figura 5: Oiliness promedio del ítem elegido, por grupo etario y región Este/Oeste. Los consumidores mayores del Japón Oriental eligen los ítems más grasosos (toro, anago), consistente con la interacción $\beta_{\text{oil} \times \text{edad}}$ significativa.

El resultado es coherente con la cultura gastronómica japonesa: el sushi tradicional “Edo-mae” (estilo Tokio) enfatiza cortes grasos e intensos, y la preferencia por estos sabores se intensifica con la edad y la experiencia culinaria.

3.3. Heterogeneidad regional Este–Oeste

Japón exhibe una división culinaria Este–Oeste documentada (el propio README del dataset la describe). M3 incluye dos interacciones con Oeste:

- $\beta_{\text{precio} \times \text{oeste}} = -0,066$ ($z = -1,46$, $p = 0,143$): evidencia débil de que el consumidor occidental es algo más sensible al precio.
- $\beta_{\text{oil} \times \text{oeste}} = -0,058$ ($z = -0,86$, $p = 0,389$): evidencia débil de que el consumidor occidental prefiere sushi menos grasoso.

Individualmente ninguna interacción alcanza significancia al 5 %. Sin embargo, la Figura 6 muestra diferencias Este–Oeste sistemáticas en los shares, y el test LR conjunto es significativo: $\text{LR} = 15,6$, $\text{gl} = 2$, $p = 4,1 \times 10^{-4}$. La debilidad individual se atribuye a la $\text{corr}(\text{precio}, \text{oiliness}) = 0,82$ dentro del Set A: el modelo no logra separar si la aversión occidental es al precio o a la grasa cuando ambos atributos se mueven juntos.




Figura 6: Diferencia de shares de primera preferencia entre Japón Occidental y Oriental, por ítem. Los ítems ligeros (ika, anago, ebi) sobre-rinden en el Oeste; toro e ikura, en el Este.

3.4. Patrones de sustitución: IIA rechazado

El Nested Logit (M4) entrega la evidencia más fuerte contra el supuesto IIA:

- $\lambda_{\text{akami}} = 0,325$: maguro, toro y tekka_maki son sustitutos **tres veces más cercanos** de lo que el MNL predice. Si toro no está disponible, el consumidor migra desproporcionadamente a maguro y tekka_maki y no hacia mariscos de otros nidos.
- $\lambda_{\text{seafood_other}} = 0,336$: correlación intra-nido similar para el grupo amplio de productos del mar.
- $\lambda_{\text{non_seafood}} \rightarrow 0$: tamago y kappa_maki son sustitutos casi perfectos; cumplen el mismo rol funcional en el choice set (la opción “hoy no quiero pescado”).

El dendrograma de clustering jerárquico (Figura 4) valida la estructura de nidos de forma independiente: la distancia de correlación de ranks entre maguro, toro y tekka_maki es mucho menor que entre cualquiera de ellos y los ítems de otros nidos. Esta convergencia

entre clustering no supervisado y el modelo estructural NL refuerza la validez de los hallazgos de sustitución.

3.5. Segmentos latentes de consumidores

El modelo de clases latentes (Tabla 6) segmenta el mercado en tres tipos de consumidor de tamaños casi iguales, con perfiles demográficos y de preferencia nítidamente diferenciados:

- **Clase a — “gourmet premium” (33,7 %).** Prefiere los mariscos intensos y caros: uni (+1,85, el ASC más alto de la clase), toro (+1,41) e ikura (+0,92); rechaza fuertemente huevo y rolls (−2,1 a −3,4). Es la clase de mayor edad (grupo etario promedio 2,13) y su membresía crece con la edad ($\gamma_{\text{edad}} = +0,18$, $t = 3,8$): la versión “entre personas” del hallazgo $\beta_{\text{oil} \times \text{edad}}$ de M3.
- **Clase b — “gusto ligero” (31,3 %).** Todos los ASCs son negativos: su ítem favorito es la referencia *ebi* (camarón), y su mayor rechazo es justamente uni (−2,19), el favorito de la clase a. Es la clase más joven (1,76), más occidental (35,7 % vs. 27,7 % de la clase c; $\gamma_{\text{oeste}} = +0,36$, $t = 3,3$) y marcadamente femenina (64,3 %; $\gamma_{\text{mujer}} = +0,81$, $t = 7,9$).
- **Clase c — “fanático del atún” (34,9 %).** Concentra su preferencia en el nido akami completo: toro (+2,84), maguro (+1,46) y tekka_maki (único segmento donde el rollo de atún tiene ASC positivo). Es la clase más masculina (43,4 % mujeres) y más oriental (27,7 % Oeste).

Tres convergencias refuerzan la validez del análisis. Primero, la clase c es la contraparte “entre personas” del nido akami del NL: la sustitución intra-atún de M4 ($\lambda_{\text{akami}} = 0,33$) y la existencia de un segmento atún-céntrico son dos manifestaciones del mismo fenómeno. Segundo, la polarización de uni detectada en el chequeo de estabilidad de ranks (Sección 2.10) queda explicada: uni es el favorito de la clase a (+1,85) y el más rechazado de la clase b (−2,19). Tercero, el gradiente etario y regional de la membresía replica las interacciones de M3 con una lectura más accionable para segmentación: los tres segmentos son direccionables por edad, género y región observables.

3.6. Calidad no observada de los ítems

La regresión OLS descriptiva de los 9 ASCs de M2 sobre los 3 atributos observables entrega $R^2 = 0,95$. El 5 % restante de variación entre ítems —capturado por los residuos de los ASCs— se interpreta como **calidad no observada**: complejidad de sabor, prestigio y asociaciones culturales no medidas en el dataset.

3.7. Limitaciones

1. **Preferencia declarada, no revelada:** los rankings expresan preferencia, no compra efectiva bajo restricción presupuestaria. El coeficiente de precio positivo es esperable en este contexto, pero limita la validez externa de los escenarios de precio.
2. **Multicolinealidad en el Set A:** $\text{corr}(\text{precio}, \text{oiliness}) = 0,82$ infla los errores estándar e impide separar limpiamente los canales de precio y grasa, en particular para la heterogeneidad Este–Oeste.
3. **Supuesto de la explosión de rankings:** el exploded logit asume estabilidad de preferencias entre etapas del ranking. El chequeo de estabilidad revela derivas no

triviales para maguro y uni: las preferencias de segunda elección no son un simple re-escalamiento de las de primera.

4. **Choice set fijo (Set A)**: los 5.000 usuarios evalúan los mismos 10 ítems. Esto habilita tests LR potentes pero limita la generalización a ítems fuera del Set A; el Set B lo aborda parcialmente.
5. **WTP no monetario**: todas las estimaciones de disposición a pagar están en unidades de precio normalizado, no en JPY; solo valen para comparaciones relativas entre atributos.

4. Scenario Analysis and Prediction (Sección C)

Se simulan cuatro escenarios contrafactuales usando constantes calibradas y los parámetros estimados (metodología en la Sección 2.2).

4.1. Escenario A — Shock de oferta del toro (+40 % precio)

Intervención: el precio normalizado del toro aumenta 40 %, simulando una reducción de cuotas de pesca de atún rojo. El escenario se simula con constantes calibradas MNL (β de M1) y con el Nested Logit (λ de M4b: $\lambda_{\text{akami}} = 0,325$, $\lambda_{\text{seafood}} = 0,336$, $\lambda_{\text{non_seafood}} = 1$; ver justificación del nido degenerado en la Sección 2.6) para contrastar IIA vs. sustitución relajada.




Figura 7: Escenario A: shares y Δ (pp) tras el shock de +40 % en el precio del toro, comparando MNL y NL. El NL predice que los ítems del mismo nido (maguro, tekka_maki) pierden *más* share que bajo MNL: consecuencia de $\lambda_{\text{akami}} = 0,325$.

Tabla 9: Escenario A — shock del toro: shares y elasticidades

Ítem	Base %	MNL %	NL %	Elasticidad cruzada (MNL)
Toro (atún graso)	34,3	59,7	67,0	1,853 (propia)
Maguro (atún)	8,1	5,0	0,6	−0,966
Anago (anguila)	11,0	6,8	6,4	−0,966
Uni (erizo)	14,9	9,2	8,7	−0,966
Ikura (huevas salmón)	10,9	6,7	6,3	−0,966
Ebi (camarón)	9,2	5,6	5,3	−0,966
Ika (calamar)	4,6	2,8	2,7	−0,966
Tamago (huevo)	4,1	2,5	2,4	−0,966
Tekka-maki (rollo atún)	2,3	1,4	0,2	−0,966
Kappa-maki (pepino)	0,7	0,4	0,4	−0,966

Todas las elasticidades cruzadas MNL son idénticas (−0,966): firma del IIA. Las del NL difieren por nido.

Caveat: $\beta_{\text{precio}} > 0 \rightarrow$ el alza de precio eleva la utilidad; ver Sección 3.1.

Hallazgo clave: bajo MNL todas las elasticidades cruzadas son idénticas (−0,966), la firma del IIA. Bajo NL, los ítems del nido akami (maguro pierde 7,4 pp; tekka_maki, 2,1 pp) se canibalizan *mucho más* de lo que el MNL predice, porque $\lambda_{\text{akami}} = 0,325$ implica sustitución cercana. Esta respuesta diferencial es el insight central: **la escasez de toro desplaza la demanda desproporcionadamente hacia los otros formatos de atún**, un patrón invisible para el MNL.

4.2. Escenario B — Promoción saludable (kappa-maki)

Intervención: kappa-maki (rollo de pepino) recibe una reducción de precio de 30 % junto a una campaña de visibilidad que eleva su `freq_sold` de 0,40 al percentil 75 (0,88). La heterogeneidad se modela con las interacciones de M3 por edad y región Este/Oeste.




Figura 8: Escenario B: shares predichos de kappa-maki por segmento demográfico, base vs. contrafactual.

Tabla 10: Escenario B — share de kappa-maki por segmento

Segmento	n	Base %	CF %	Δ (pp)
Joven Este	2.515	0,523	1,234	+0,711
Mayor Este	933	0,337	0,797	+0,460
Joven Oeste	1.126	0,701	1,650	+0,949
Mayor Oeste	426	0,451	1,066	+0,614
Total	5.000	0,522	1,232	+0,709

La ganancia de share la domina el aumento de `freq_sold` ($\beta_{\text{freq}} = +2,17$).

La rebaja de 30 % en el precio *reduce* utilidad porque $\beta_{\text{precio}} > 0$; el efecto neto viene de la disponibilidad.

Hallazgo clave: el efecto absoluto es modesto (+0,71 pp), consistente con la expectativa honesta de que kappa-maki (share base 0,52 % en el modelo con interacciones) es fundamentalmente impopular. El efecto de $\beta_{\text{freq_sold}}$ domina el contrafactual. Los jóvenes occidentales muestran la mayor respuesta (+0,95 pp), consistente con el hallazgo de M3 de que el Oeste interactúa negativamente con la grasa: kappa-maki es el ítem menos grasoso del Set A.

4.3. Escenario C — Entrada del California roll

Intervención: una cadena americana introduce un California roll al mercado japonés. El ítem nuevo se modela con `precio` = 1,5, `oiliness` = 2,0, `freq_sold` = 0,50 y `estilo` maki. **Modelo:** M6 (solo atributos, Set B, universo de 100 ítems): al predecir un ítem nuevo sin ASC, el modelo de atributos es el único honesto. Supuesto declarado: la calidad no observada del entrante iguala el promedio; análisis de sensibilidad de $\pm 0,5$ en esa constante.

Tabla 11: Escenario C — share predicho del California roll + canibalización (top 5)

Ítem	Base %	CF %	Δ (pp)
California roll (nuevo)	0,00	1,50 (0,91–2,44)	+1,50
Toro (atún graso)	9,50	9,36	−0,14
Uni (erizo)	5,13	5,06	−0,08
Ikura (huevas de salmón)	4,48	4,42	−0,07
Anago (anguila)	4,58	4,51	−0,07
Maguro (atún)	4,49	4,43	−0,07

La canibalización es proporcional a los shares base (propiedad IIA del MNL M6).

Sensibilidad: share en [0,91 %; 2,44 %] con $\pm 0,5$ en la constante de calidad no observada.

Hallazgo clave: el share predicho es 1,50 % (rango de sensibilidad 0,91–2,44 %). La canibalización sigue el patrón proporcional que dicta el IIA: los ítems más populares (toro, uni) pierden más en términos absolutos. Es una *limitación declarada*: sin información de nido para el ítem hipotético no puede afirmarse que canibalice más a otros maki. Los shares base de esta tabla son los predichos por M6 (no los observados): el ejercicio compara el universo de 100 ítems con y sin el entrante bajo el mismo modelo.

4.4. Escenario D — Campaña regional Kinki

Intervención: una rebaja de 20 % en el precio de cuatro ítems tradicionales de Kansai —battera, saba (caballa), tai (pargo) y hamo (congrio picudo)— dirigida exclusivamente a los residentes de la región Kinki ($n_{\text{Kinki}} = 978$). **Modelo:** M6 (Set B), con shares ponderados (los usuarios Kinki enfrentan los precios contrafactuales; el resto, los precios base).

Tabla 12: Escenario D — campaña Kinki, shares ponderados

Ítem	Base %	Solo Kinki %	Ponderado %	Δ (pp)
Battera	0,12	0,11	0,12	−0,002
Saba	1,13	1,05	1,11	−0,020
Tai	2,07	1,86	2,03	−0,043
Hamo	0,13	0,12	0,13	−0,002

Todos los deltas son negativos porque $\beta_{\text{precio}} = +0,251 > 0$: bajar el precio reduce la calidad percibida. El efecto ponderado se diluye porque Kinki es solo el 19,6 % de la muestra.

Hallazgo clave: el efecto predicho es esencialmente nulo (el mayor Δ es −0,04 pp para tai). El problema $\beta_{\text{precio}} > 0$ es especialmente agudo aquí: una *rebaja* de precio señala menor calidad y reduce utilidad. Incluso con β_{precio} negativo, los shares base de estos ítems son tan pequeños (0,1–2,1 %) que los efectos absolutos seguirían siendo modestos. La lección es metodológica: **las intervenciones de precio no pueden evaluarse de forma creíble con este dataset**, porque el precio funciona como señal de calidad y no como costo.

5. Strategic and Public Policy Recommendations (Sección D)

5.1. Para cadenas de restaurantes y retail de sushi

Diseño de menú informado por sustitución. El hallazgo del Nested Logit ($\lambda_{\text{akami}} = 0,325$) tiene implicancias directas para inventario y menú:

- Cuando el toro se agota, la demanda *no* se reparte uniformemente por el menú: se concentra en maguro y tekka_maki, los ítems de su mismo nido. Un restaurante que anticipe escasez de toro debe reforzar el stock de maguro y tekka_maki, no reponer proporcionalmente.
- A la inversa, el nido non_seafood ($\lambda \rightarrow 0$) implica que tamago y kappa_maki se perciben como intercambiables. Agregar una tercera opción sin pescado probablemente canibalice a estas dos en vez de expandir el mercado.

Estrategia de entrada al mercado. El escenario del California roll (Sección C.3) sugiere un share de entrada modesto de 1,5 % (rango 0,9–2,4 %): no trivial para un solo SKU nuevo en un mercado de 100 ítems. El patrón de canibalización proporcional (IIA) implica que el entrante quitaría share a todos los ítems en proporción a su popularidad.

Segmentación etaria y regional. Los hallazgos de M3 y del modelo de clases latentes (Secciones 3.2 y 3.5) indican que las campañas de ítems premium grasos (toro, anago,

uni) deben dirigirse a consumidores mayores del Japón Oriental, mientras que los ítems ligeros y vegetales (kappa_maki, tamago) resuenan más en jóvenes y en el Oeste.

5.2. Para la política de salud pública

Las campañas de alimentación saludable basadas en precio difícilmente funcionarán en el mercado del sushi. El escenario de kappa-maki (Sección C.2) muestra que incluso con una rebaja de 30 % y un fuerte impulso de disponibilidad, el share del ítem más saludable del Set A sube solo 0,7 puntos porcentuales (de 0,52 % a 1,23 %).

Más importante: $\beta_{\text{precio}} > 0$ en todas las especificaciones implica que el consumidor japonés usa el precio como heurística de calidad al evaluar sushi. Un “sushi saludable” subsidiado se percibiría como de *menor calidad*, socavando la intervención. Las campañas deberían usar palancas distintas del precio:

- **Disponibilidad y visibilidad:** $\beta_{\text{freq_sold}} = +2,17$ (el mayor coeficiente de atributo) sugiere que aumentar la presencia de opciones saludables en menús y tiendas tiene un efecto real.
- **Educación y framing:** en vez de bajar el precio, reposicionar los estilos ligeros como elecciones premium de artesanía culinaria, no como “alternativas saludables baratas”.

5.3. Para la preservación cultural regional

El escenario Kinki (Sección C.4) revela una limitación metodológica: las estrategias de preservación cultural vía precio no pueden evaluarse con este dataset. Los cuatro ítems tradicionales de Kansai tienen shares base minúsculos (0,1–2,1 %) y el confounding precio-calidad hace ininterpretable el contrafactual. Un camino más productivo:

- Levantar datos de preferencia revelada (compras efectivas) donde β_{precio} sea negativo y los escenarios de precio tengan sentido.
- Explorar intervenciones no-precio: designación de patrimonio culinario, promoción turística, campañas educativas sobre tradiciones regionales.
- Las diferencias Este–Oeste documentadas en la Sección B.3 muestran que el regionalismo culinario es real y medible: los esfuerzos de preservación deberían apalancar esa identidad existente.

5.4. Recomendaciones metodológicas para trabajo futuro

1. **Datos de preferencia revelada:** transacciones reales con precios pagados resolverían el confounding $\beta_{\text{precio}} > 0$ y harían interpretables el WTP y los escenarios de precio en términos monetarios.
2. **Variación de atributos a nivel individual:** si los consumidores enfrentaran precios o composiciones distintas (p. ej. vía diseño experimental), betas de atributos y ASCs serían identificables conjuntamente sin calibración.
3. **Mixed Logit:** una especificación con coeficientes aleatorios continuos complementaría al modelo de clases latentes para capturar la heterogeneidad residual dentro de clase (la deriva de ranks de uni y maguro).
4. **Estructura de nidos en el Set B:** extender el NL al universo de 100 ítems permitiría un análisis de sustitución más rico y simulaciones de entrada más realistas.

Bibliografía

1. Beggs, S., Cardell, S., & Hausman, J. (1981). Assessing the potential demand for electric cars. *Journal of Econometrics*, 17(1), 1–19.
2. Hess, S. & Palma, D. (2019). Apollo: A flexible, powerful and customisable freeware package for choice model estimation. *Journal of Choice Modelling*, 32, 100170.
3. Kamishima, T. (2003). Nantonac Collaborative Filtering: Recommendation Based on Order Responses. *Proceedings of KDD2003*, 583–588.
4. McFadden, D. (1978). Modelling the choice of residential location. En *Spatial Interaction Theory and Planning Models* (pp. 75–96).
5. Train, K. (2009). *Discrete Choice Methods with Simulation* (2.^a ed.). Cambridge University Press.

Linkografía

- Dataset original: <https://www.kamishima.net/sushi/>
- Carpeta compartida con datos y scripts: **PENDIENTE: insertar link (Drive/GitHub) antes d**

A. Apéndice: trade-offs relativos entre atributos

Tabla 13: Trade-offs relativos (no son WTP monetario; ver Sección 3.1)

Modelo	Trade-off	Estimación	EE	IC 95 %
M1	Oiliness / Precio	-0,147	0,067	[-0,278; -0,016]
M1	Freq_sold / Precio	-3,739	0,278	[-4,283; -3,195]
M6	Oiliness / Precio	-1,659	0,208	[-2,067; -1,251]
M6	Freq_sold / Precio	-17,174	1,632	[-20,372; -13,976]
M6	Maki / Precio	-2,338	0,379	[-3,080; -1,596]
M6	Non-seafood / Precio	1,498	0,357	[0,798; 2,199]

Método delta sobre $-\beta_k/\beta_{\text{precio}}$. Con $\beta_{\text{precio}} > 0$ el ratio no es disposición a pagar.

B. Apéndice: estructura del repositorio de código

scripts/	
config.py	Configuracion central
process_sushi_dataset.py	Pipeline raw -> CSV (mapeo Set A corregido)
verify_sushi_dataset.py	47 checks de integridad de datos
01_eda_visualizations.py	11 figuras + 5 tablas resumen
02_estimate_models.py	M1, M2, M3, M6 (scipy BFGS, grad. analitico)
03_exploded_models.py	M4/M4b Nested Logit (ranking explotado)
04_scenario_analysis.py	4 escenarios contrafactuales con calibracion
R_Studio/	
apollo_config.R	Configuracion Apollo
apollo_data_prep.R	Pivot long -> wide + explosion de ranks
01_apollo_mnl.R	M1, M2, M3 (validacion cruzada, LL identicas)
02_apollo_nested_logit.R	M2exp y M4b (validacion cruzada)
03_apollo_latent_class.R	M5-LC: clases latentes (2 y 3 clases)
EXPLICACION_MODELOS_R.txt	Guia de cada modelo R y sus conclusiones

Todos los scripts Python son reproducibles (SEED = 42). Los scripts de Apollo se ejecutaron con R 4.5.3 y Apollo 0.3.7; sus archivos de salida (APOLLO*_output.txt, *_estimates.csv) quedan en outputs/tables/ como evidencia de ejecución.